

# 利用类别信息量寻求长尾目标检测的更优决策边界 (IGAM)

## 摘要:

长尾目标检测（目标识别）场景下，长尾的传统定义以类别实例数量进行统计，然而探究表明（动机），长尾类别与模型偏差并非完全相关（传统的平衡方案，直接基于类别实例数量进行平衡，效果并非很好，未来深入探究平衡-实际上可以延伸我们的流形空间的工作，在流形空间重新度量类别有效信息空间），其次非长尾场景下，模型仍然偏差（需要新维度度量偏差本征），我们发现，类别的信息量（与数据集无关，与自然类别本身有关（因此，泛化能力强），某个类别充斥的信息量，即被学习的难度）影响模型的训练效果（偏差程度），基于此我们提出基于类别信息量的角度间隙损失（Information Amount-Guide Angular Margin Loss-IGAM），IGAM Loss 在长尾和非长尾目标检测数据集上均表现出最优的效果。

角度间隙 Angular Margin：在特征向量之间引入角度间隙，压缩同类特征的空间，间隔异类特征的空间，从而实现更清晰的决策边界，类似于 CLIP 的度量学习

## 引言:

### 动机:

长尾分布普遍存在于目标检测任务，传统的长尾观念认为，模型偏差是由于实例数量的不平衡，而最新的工作表明，偏差不仅由类频率影响，还与类特征的复杂性有关。我们对平衡目标检测数据集 Pascal VOC 进行实例数量与类平均精度（AP）的相关性分析，两者的相关性很低（图 1），这表明，模型偏差不仅由类频率影响，更有可能受到类特征的复杂性的影响。

### 以往工作分析:

通过类实例频率进行加权，或通过数据增强技术，来缓解长尾，但是这些工作都聚焦于实例数量，而非类复杂性，因此模型可能忽略了真正弱势的类别，从而限制了整体的性能。

### IGAM 工作分析:

为了揭示模型偏差的本质，我们引入类别信息量作为新的度量方法，我们量化了一个类别的实例多样性，即自然类别充斥的信息量，我们认为类信息量越大，模型学习难度越大，通过在平衡数据集 Pascal VOC 和长尾数据集 LVIS v1.0、COCO-LT 上的类别信息量与 AP 的相关性（表 1、图 2），表明类别信息量更能反映模型偏差，因此，我们希望利用类别信息量将模型的注意力引导至真正弱势的类别。

从决策空间的角度分析，数据量的不平衡（类频率长尾）导致头类固有的获得较大的

决策空间，尾类固有的获得较小的决策空间，而前面的探究表明了这种类频率划分的长尾并不能很好的表征模型偏差，因此通过类频率进行平衡的决策空间是病态的，类信息量越小，模型学习的难度越低，所需的决策空间越小，